

A ÉTICA COMO GUIA PARA O USO DA INTELIGÊNCIA ARTIFICIAL GENERATIVA

LUCIA SANTAELLA¹ 

RESUMO: Desde a revolução industrial, intensificada pela revolução eletrônica, as sociedades vêm sendo impactadas por transformações tecnológicas que afetam, sobretudo, as linguagens e a cognição humana. Os impactos aprofundaram-se a partir da instauração da internet até alcançarem hoje a era da dataficação monitorada pelos algoritmos de inteligência artificial. O campo da educação não poderia ficar à margem dessas transformações. Infelizmente, desde que a Inteligência Artificial Generativa (IAG) caiu nas sociedades feito um meteoro, dilúvios de discursos muito mais opinativos do que bem-informados têm gerado mal-entendidos e aversões sem fundamentos. Este artigo tem por objetivo elucidar o caminho da IAG para fins educacionais que termina na discussão de uma publicação recente de um manual e guia para o uso da IAG nos meios acadêmicos.

Palavras-chave: Dataficação. Inteligência artificial generativa. Educação. Manual. Guia.

ETHICS AS A GUIDE FOR THE USE OF GENERATIVE ARTIFICIAL INTELLIGENCE

ABSTRACT: Since the industrial revolution, intensified by the electronic revolution, societies have been impacted by technological transformations that affect, above all, human languages and cognition. The impacts have deepened since the establishment of the internet until today they reach the era of datafication monitored by Artificial Intelligence algorithms. The field of education could not remain on the sidelines of these transformations. Unfortunately, since Generative Artificial Intelligence (GAI) fell upon societies like a meteor, floods of discourses that are much more opinionated than well-informed have generated misunderstandings and unfounded aversions. This article aims to elucidate the path of GAI for educational purposes, ending with the discussion of a recent publication of a manual and guide for the use of GAI in academic circles.

Keywords: Datafication. Generative artificial intelligence. Education. Manual. Guide.

LA ÉTICA COMO GUÍA PARA EL USO DE LA INTELIGENCIA ARTIFICIAL GENERATIVA

RESUMEN: Desde la revolución industrial, intensificada por la revolución electrónica, las sociedades se han visto impactadas por transformaciones

1. Pontificia Universidade Católica de São Paulo  – Faculdade de Ciências Exatas e Tecnologia – Programa de Estudos Pós-Graduados em Tecnologias da Inteligência e Design Digital – São Paulo (SP), Brasil. E-mail: lbarga@pucsp.br

Editores de seção: Antônio A. Soares Zuin  e Pedro Goergen 

tecnológicas que afectan, sobre todo, a los lenguajes y a la cognición humana. Los impactos se han profundizado desde el establecimiento de Internet hasta llegar a la era actual de la datificación monitoreada por algoritmos de inteligencia artificial. El campo de la educación no podía quedar al margen de estas transformaciones. Lamentablemente, desde que la Inteligencia Artificial Generativa (IAG) cayó en las sociedades como un meteoro, una avalancha de discursos mucho más opinativos que bien informados han generado malentendidos y aversiones infundadas. Este artículo pretende dilucidar el camino de la IAG con fines educativos, que finaliza con la discusión de una reciente publicación de un manual y guía para el uso de la IAG en entornos académicos.

Palabras clave: Datificación. Inteligencia artificial generativa. Educación. Manual. Guía.

Introdução

Embora não se fale em outra coisa, a maior parte dos discursos sobre Inteligência Artificial (IA) – ou melhor, aqueles que mais causam impacto –, mesmo quando disfarçados, são discursos meramente opinativos, amedrontados e negacionistas. Ronda, portanto, uma confusão generalizada sobre a história, a natureza, os propósitos e, em especial, sobre a onipresença da IA na vida social, política, cultural, estética e pessoal.

Nesse contexto, para chegarmos à questão da IA e seus efeitos na educação, um retrospecto é necessário para que se possa perceber o processo evolutivo e os desafios pelos quais os sistemas educacionais vêm passando desde pelo menos o momento em que a cultura mediada por computador se instalou nas sociedades como um todo e, conseqüentemente, também na educação.

A aprendizagem depende de alguma forma de transmissão. Entende-se por transmissão a passagem da memória cultural intergerações, o que já existe desde tempos imemoriais, quando o que chamamos de educação ainda não havia se instaurado, mas já existia a transferência das representações de mundo das gerações mais velhas com vistas ao preparo das mais jovens. O que se pretende enfatizar com isso, no entanto, é que não há transmissão sem meios ou mediações pelos quais ela se opera. Nas sociedades antigas, por exemplo, as narrativas míticas funcionavam como formas de mediação.

Modelos Educacionais Pós-Digitalização

Para nos situarmos historicamente mais perto das questões a serem discutidas neste texto, bastante significativa foi a era do livro, depois da invenção de Gutenberg, quando a reprodutibilidade da escrita incrementou e regrou os processos educacionais a ponto de se poder afirmar que, nesse contexto, o livro passou a se constituir na base norteadora dos processos de ensino e aprendizado, aliada à transmissão vetorizada do professor na direção do aluno. Esses princípios, até então soberanos, tiveram que enfrentar a competição diferenciadora e muito atraente dos meios de comunicação de massa: o jornal (híbrido entre cultura livresca e de massa), a fotografia, o cinema, o rádio, a TV etc.

O que aí se apresenta que, de fato, implica competição é a ascensão de linguagens não verbais (visuais, sonoras, audiovisuais) muito mais sedutoras do que a linguagem verbal que ainda hoje é considerada, tardiamente por alguns, como a única e exclusiva detentora do conhecimento em detrimento das outras linguagens. A educação formal buscou formas de modesta aliança, por exemplo, com os telecursos e seus

resultados duvidosos. Isso implodiria com a chegada do digital que não só embaralhou, mas mudou todas as cartas do jogo. Não demorou para que a digitalização, substituindo uma cultura midiática, entronizasse uma cultura das redes em que todas as atividades humanas passaram a ser incorporadas a elas, inclusive, certamente, a educação.

No início, falava-se em cultura do computador, mas muito rapidamente o computador foi se tornando uma mídia de todas as mídias e trazendo desafios para os modelos educacionais, muito especialmente para o modelo tradicional baseado na centralidade do livro. A partir dos anos 1990 começaram a surgir vários submodelos pedagógicos responsivos ao advento da cultura digital, também chamada de cibercultura. Por essa época, o design instrucional estava na agenda dos educadores mais alertas. Esses modelos iam sendo implantados na dependência das variações geoeconômicas e geopolíticas que são próprias de um país como o Brasil; variações que ficaram muito óbvias em termos educacionais durante a pandemia, quando as escolas de elite tinham os meios para substituir rotinas presenciais, enquanto outras, em estado de carência, viram suas crianças desprovidas de escolaridade.

Desde que escrevi o livro *Navegar no ciberespaço: o perfil cognitivo do leitor imersivo* (Santaella, 2004), por razões que não previa, passei a acompanhar e me familiarizar com grupos de pesquisadores engajados na incorporação dos vários submodelos educacionais pós-digitalização. Não me canso de repeti-los pelo simples fato de que considero equivocado tratar como uma tábula rasa o atual *hype* da dataficação e da IA, especialmente quando a educação entra em jogo. As adaptações e preocupações atuais das relações da IA com os processos de ensino e aprendizagem foram precedidas por adaptações específicas bem ou mal resolvidas nas fases da aprendizagem em ambientes virtuais e dos designs instrucionais (anos 1990); e, então, da aprendizagem móvel (anos 2000), seguida da aprendizagem ubíqua (depois de 2010), inclusive do *app learning* (Couto; Porto; Santos, 2016) e de outros tipos de explorações levadas a efeito por escolas e professores corajosos, capazes de fazer frente às típicas tendências à inércia dos processos educacionais.

Além disso, é preciso considerar que as ecologias tecnológicas são entrelaçadas. A IA não emergiu do nada, nem encontrou um campo vazio para se instalar. A cultura do livro não morreu, apenas perdeu sua soberania. As culturas midiáticas não desapareceram, apenas foram capturadas nas teias das redes. O que se pode esperar é que todas elas passem por mutações introduzidas pela IA.

Aplicativos de IA, especialmente no Norte Global, já começaram a ser introduzidos na educação há anos (Looi *et al.*, 2005; Luckin *et al.*, 2016; Dickson, 2017; Holmes; Bialik; Fadel, 2019; Organização das Nações Unidas para a Educação, a Ciência e a Cultura [Unesco], 2019, 2021; ProFuturo; OEI, 2023). Aqui no Brasil, antes da chegada da IA generativa (IAG), que começa a despertar grande interesse de autores e educadores, as publicações com relatos de experiência eram poucas, o que não é surpreendente dada a dispersão e fragmentação brasileira, evidente na falta de projetos temáticos coletivos e robustos que possam chegar, inclusive, até a fase de avaliação e autocorreção, de modo a servir como exemplos para projetos futuros. Mas isso só vem comprovar que a descontinuidade é uma das grandes fragilidades deste país, afetando também a educação.

A Era da Dataficação Monitorada por IA

Em suma, desde que a revolução digital se instalou, as sociedades humanas têm sido atropeladas por inovações cada vez mais profundamente disruptivas, que vão penetrando sub-repticiamente nas finas e íntimas nervuras das práticas humanas. Não deveria ser novidade que já alcançamos a segunda idade da internet; quer dizer, embora ainda estejamos sob o império da digitalização, estamos na era da dataficação

(Santaella, 2021). Tudo que nos rodeia virou dado, inclusive nós mesmos. Além de seres de carne e osso, somos também dados. Circulam pelas nossas vidas, quase naturalizados, temas como computação na nuvem, internet das coisas ou comunicação máquina-máquina, big data, cidades inteligentes e a grande personagem reinando sobre tudo isso: a IA.

Não custa repetir, como tenho feito em várias ocasiões, que não existe uma só IA. Trata-se hoje de um campo vasto e variado de aplicações em quase todas as áreas de produção e práticas humanas. Por meio de técnicas de aprendizagem de máquina e aprendizagem profunda, a IA analisa, padroniza e recupera dados; faz previsões e recomendações; automatiza uma grande quantidade de tarefas por meio, especialmente, de agentes pessoalizados; ela também traduz, vê, ouve, entende e responde em vários idiomas. Ademais, faz diagnósticos médicos, e os robôs ficam cada vez mais especializados para atendimento a tarefas repetitivas.

No cenário impactante que se desenha, faz-se notar, desde o final de novembro de 2022, a irrupção social provocada pela IA generativa e seu mascote, o ChatGPT, que caíram no mundo feito um meteoro. Em meio ao *hype*, infelizmente são poucos aqueles que estão vendo a premente necessidade de distinguir a IA classificatória e preditiva, de um lado, e a IAG, de outro. Se é certo que ambas trabalham com bilhões de dados humanos e com aprendizagem de máquina e aprendizagem profunda, também é certo que seus funcionamentos e suas consequências benéficas e negativas são distintas, em todos os campos em que se aplicam – especialmente, para ficarmos no nosso tema, na educação.

Contudo, temos de convir que, embora não se fale em outra coisa, a maior parte dos discursos sobre IA – ou melhor, aqueles que mais causam impacto –, mesmo quando disfarçados, são discursos meramente opinativos, amedrontados e negacionistas. Ronda, portanto, uma confusão generalizada sobre a história, a natureza, os propósitos e, em especial, sobre a onipresença da IA na vida social, política, cultural, educacional, estética e pessoal, especialmente depois da chegada da IAG.

Distinções entre IA Preditiva e IA Generativa

Basta uma breve menção relativa ao modo como IA preditiva e a IAG trabalham para que seja possível perceber tanto suas diferenças quanto, o que é importante para nós – já que temos de colocar o olho no presente e nas determinações que apontam para o futuro –, as perspectivas que se anunciam, a saber, as profundíssimas disrupções que a IA generativa está fadada a provocar nos sistemas educacionais e processos pedagógicos.

É certo que a IA preditiva habita os nossos celulares, mas dela só recebemos sinais, pois ela opera de modo invisível debaixo do capô do smartphone. Mas a verdadeira morada da ciência de dados e da IA preditiva é a dos desenvolvedores, que prestam serviços para as tomadas de decisões mais rápidas e estratégicas das corporações e instituições. Consideradas as suas externalidades negativas, esse tipo de IA ocupa a preocupação política dos legisladores dada a urgência das regulamentações com vistas ao atendimento dos direitos fundamentais.

Como funciona a IA preditiva e por que se chama preditiva? Imediatamente é possível inferir que ela é preditiva porque é capaz de prever resultados futuros. Como ela funciona para que isso seja possível? Ela ingere grandes volumes de dados históricos de diferentes fontes, relevantes para o problema que lhe é colocado. Então os algoritmos de aprendizado de máquina analisam esses dados buscando tendências, padrões e relacionamentos entre variáveis. Por isso ajudam na tomada de decisões e na formulação de estratégias.

A IAG, por seu lado, é muitíssimo diferente; uma diferença capaz de explicar o tsunami que invadiu nossas sociedades desde que foi colocada nas mãos do público. Esse foi o ChatGPT 3.5, acompanhado pela IA generativa de imagens que tem abalado os circuitos das artes e a indústria criativa de produtores visuais e textuais.

A IA generativa é um subconjunto do aprendizado profundo, mas de um tipo diferente, chamado de *modelo gerativo*, que aprende com um conjunto subjacente de dados para gerar novos dados que imitam de perto os dados originais. Por meio do emprego de aprendizagem não supervisionada, esses modelos são usados principalmente para criar novos conteúdos, como imagens, texto ou até mesmo música, semelhantes àquilo que pode ser criado por humanos.

Em agosto de 2023, publiquei um livrinho com a seguinte pergunta: *Há como deter a invasão do ChatGPT?* (Santaella, 2023). O protagonismo do Chat no título se deve ao fato de que esse Chat, de fato, se tornou o mascote da IA generativa, dado o abalo sísmico e a histeria por ele provocada. A histeria não cessa, pois do 3.5 passamos para o 4, seguido pelo 4-o – o de *omni*, que em latim quer dizer todos, ou melhor, todas as linguagens, pois se trata da competência do sistema em manipular todos os tipos de linguagens que o humano preza como sendo suas. Há pouco mais de um ano, deixei vaga a resposta se a invasão do Chat poderia ser detida ou não. Hoje, afirmo peremptoriamente: não pode ser detida. E por quê?

Diferentemente da IA preditiva, a IAG é um sistema de uso pessoal que caiu direto no colo de qualquer ser humano que disponha de um computador minimamente equipado, que saiba ler e escrever; agora basta que saiba falar e tenha disponibilidade para o diálogo, quando pode ver tarefas que lhe custavam tempo sendo realizadas rapidamente por um sistema solícito e gentilmente prestativo. É certo que não se pode confiar nos equívocos e erros em que o Chat e seus competidores certamente incorrem. Mas desenvolver a suspeita e os cuidados no seu uso devem ser tarefas educativas a serem assumidas.

Embora não possamos descartar as incertezas e inseguranças quanto ao futuro, em nosso papel de pensadores e educadores, temos que olhar de frente para o modo como a IAG está penetrando em todas as nervuras de nossas vidas e para a maneira como crescem suas externalidades negativas em relação aos direitos humanos – em especial, nesse caso, a direitos autorais, perdas de empregos e outras consequências previsíveis e imprevisíveis.

Olhar de frente significa reconhecer que a IA generativa está sendo explícita ou implicitamente usada pelos mais diversos profissionais. Dentre aqueles que enfrentam tarefas relativas às linguagens, são poucos os que não a estão experimentando. Em suma, além de ser uma tarefaira multitalentos, a IAG penetrou no cerne semiótico do humano; ela ouve, fala, dialoga e, além do mais, é gentil. Dada a competitividade que reina entre as big techs e os vultosos investimentos que entram em jogo, não cessam os aperfeiçoamentos dos sistemas. Em pouquíssimo tempo, por exemplo, o ChatGPT 4-o foi aprimorado no ChatGPT-o1, que pretende pensar como os humanos pensam (cf. Santaella, 2024).

Questões Pensadas a Partir do Chão da Escola

Quando passamos essas informações para o chão da escola, constata-se que, no Brasil, os aplicativos de IA preditiva nos processos pedagógicos já se apresentavam lacunares e até mesmo nulos. Agora, o que dizer das condições que estamos enfrentando pós-IAG? É preciso enfrentar o fato de que a IA generativa inaugura novíssimos problemas. Os jovens começaram brincando com o Chat, e hoje esse Chat está sendo utilizado incorporado de modo invisível especialmente pelos discentes do ensino médio e do superior, com consequências a que as instituições de ensino estão preguiçosamente cegas. É preciso acordar. Essa nova forma

de inteligência parceira e solícita, sem deixar de ser enganadora, está implodindo os sistemas educacionais – em particular as suas formas de avaliação.

De fato, em especial no ensino médio e sobretudo no superior, poucos estão resistindo às solitudes sempre à mão da IA generativa. Proibir seu uso deve estar entre os piores caminhos, pois o proibido acaba por incentivar o uso oculto, cuja detecção, apesar de promessas dos desenvolvedores, não é ainda segura. Já dizia Freud que o proibido é a condição do gozo. Isso vale para todos os campos. Por outro lado, ignorar significa alienar-se de um problema que exige atenção e encaminhamentos. A questão mandatória que agora se coloca é ética, o que implica, antes de tudo, informar-se, conhecer, experimentar e avaliar para melhor agir.

Minhas preocupações relativas à IA sempre estiveram focadas no humano, ou seja, naquilo que vem sendo chamado de IA centrada no humano. Considerando-se a penetração com que o ChatGPT está se insinuando nas várias atividades humanas que dependem da linguagem, surpreende e preocupa a sonolência das universidades brasileiras de que tenho conhecimento, inertes diante do enorme desafio que a educação superior está enfrentando e que só não estão vendo aqueles que seguem deliberada ou involuntariamente indiferentes. Diante disso, resolvi, há alguns meses, junto com um grupo de estudantes de excelência, tomar uma atitude, a saber, criar um manual seguido de um guia para a formação de professores. Muitos educadores estão desorientados. É preciso trazer alguma luz ao seu caminho.

Um Manual e Guia para o Uso Educacional da IA Generativa

Assim, o que apresentarei a seguir é uma súmula de um número da *Revista Teccogs* n. 23, da qual sou vice-diretora científica, inteiramente dedicado ao desenvolvimento de um manual informativo e avaliativo, seguido de um guia para a orientação dos educadores. Supervisionado muito de perto por mim, o manual é fruto de um trabalho coletivo, o resultado de estudos e discussões desenvolvidos em vários meses até chegarmos ao ponto que o grupo julgou satisfatório. O trabalho nasceu da constatação de que alguma iniciativa deveria ser tomada em prol do desenvolvimento ético para o uso da IA generativa no meio acadêmico.

Do mesmo modo que dirigimos um carro sem a necessidade de conhecer aquilo que está debaixo do capô, fazer uso da IAG não depende de qualquer conhecimento de qualquer espécie sobre quais são as determinações internas e como ela age. Desde a instauração das redes sociais, os usuários digitais acostumaram-se a ocupar seus espaços sem nenhum entrave. A IAG entrou nesse fluxo, em que tudo é facilitado para a habitação em uma ecologia tão amigável quanto ocultadora de todos os efeitos colaterais que provoca.

Não é casual o verdadeiro tsunami provocado pelo ChatGPT, um multitarefeiro conversador e solícito, sempre pronto não só a ajudar, mas também a fazer por nós. Aí mora o perigo. Por isso, o manual contém não apenas um guia ético, mas deve funcionar como um alerta ético no campo da educação. Na verdade, enquanto a IA preditiva lida sobretudo com riscos, a IAG tem na ética sua chamada magna. Educar para a ética tornou-se mandatório.

O manual tem início com o tema dos direitos humanos. Certas aplicações da IA têm o potencial ambivalente de afetar direitos fundamentais, justamente por serem capazes de gerar mais eficiência e celeridade nas atividades humanas. Mas a ambivalência provém principalmente das várias externalidades negativas da IA, especialmente aquelas que ferem os direitos humanos. De autoria de dois juristas preocupados com os destinos que a IA está preparando para os humanos, o artigo explicita os riscos, em que contextos eles acontecem e quais iniciativas vêm sendo tomadas contra eles.

A seguir, o tema da ética é olhado de frente. Falar de ética se tornou um leitmotif dos artigos sobre IA. Entretanto, há que se diferenciar as árvores da floresta. Ética não é uma coleção de regrinhas para os bons costumes. Isso pode até ser importante, mas é preciso considerar que há uma ética teórica, filosófica, e uma ética prática. A ética teórica está voltada para a determinação dos ideais coletivos que devem iluminar e conduzir a vida humana. A ética prática coloca em ação esses ideais em condições situadas. Neste caso, o segundo artigo do manual está voltado para os dilemas éticos da IAG para o ensino em metamorfose.

Diante dos dilemas existentes, é necessário buscar novos modelos de ensino superior que incorporem as novas tecnologias. Conectividade, acessibilidade, plataformização e ubiquidade são pilares fundamentais, mas também é essencial manter como farol a promoção de instituições comprometidas com a crítica, legitimadas nos campos envolvidos, responsivas a desafios em diferentes esferas, representativas, produtoras de conhecimento rigoroso e indutoras de desenvolvimento socioeconômico. Peças fundamentais dessa transformação são as questões éticas e os modelos de governança atentos em potencializar seus benefícios sem deixar de olhar para os riscos associados.

A tendência à antropomorfização da IA tem provocado muitas confusões e mais dilemas a serem enfrentados. De fato, uma das principais razões de confusões que rondam a compreensão daquilo que a IAG é ou não capaz de realizar consiste em tomá-las à imagem e semelhança dos humanos, como se fossem, inclusive, capazes de sentimentos ou como se elas próprias fossem racistas. Diante disso, o artigo seguinte colocou em discussão quais os limites das IAGs e qual papel os humanos desempenham no uso que fazem delas (cf. Röhe, 2024).

O resultado esperado é desmistificar a eficácia das IAs para a detecção de emoções ou para comportamentos éticos, sobretudo em relação aos cuidados a serem tomados em ambientes vulneráveis como a sala de aula. Perguntas do tipo se as IAs sentem, se elas mentem, se elas são racistas foram devidamente debatidas. Uma vez que essas perguntas têm recebido como respostas afirmações quase sempre distorcidas, vale a pena adiantar aqui algumas súmulas explicativas.

As IAGs sentem? Embora os robôs falantes criem a ilusão de que sentem, o que fazem, na verdade, é encontrar determinados padrões de sentimentos a partir da quantidade de vezes que certo tipo de pergunta foi feita. Embora se comporte como uma máquina consciente e pensante, não se trata de um modelo senciente, já que não sente, mas apenas simula sentir sem fazer a menor ideia daquilo que está falando. Entretanto, não saber do que fala não é o que importa, mas sim criar no receptor a ilusão de que o robô sente.

De fato, não passa de ilusão, pois de acordo com a neurociência a emoção no humano solta faíscas elétricas no cérebro em conexões dinâmicas com todas as partes do corpo. Por isso, a IA ainda não é capaz de modelar estados da mente, em especial as emoções, pois elas dependem de hormônios e neuromoduladores. Alguns cientistas se gabam de que o metabolismo pode ser moldado em computadores, mas não são capazes de apresentar um só exemplo concreto.

As IAGs mentem? Mentir apresenta uma semântica muito peculiar. A mentira é distinta do erro, do lapso, da hipocrisia e do cinismo. Enquanto o erro e o lapso não são deliberados, na hipocrisia e no cinismo há sempre uma certa dose de deliberação, mesmo que vaga. Mas só há mentira quando houver uma intencionalidade para mentir, cujo alvo é enganar, ou seja, fazer crer em algo que trai a realidade dos fatos.

A IA, por seu lado, não está programada para dizer a verdade ou a mentira, e sim gerar conteúdos coerentes para os humanos a partir da base de dados usada no seu treinamento. Portanto, a IA não é responsável pelo que apresenta. Isso não é a mesma coisa que negar que ela possa ser usada pelos humanos para mentir, enganar, tripudiar e todos os outros tipos de maledicências que hoje encontram nas redes da web um fluxo promissor para serem disseminadas. Entretanto, dizer que a IA não dispõe da intencionalidade para mentir está longe de significar que ela não possa ser usada para isso. Notório, por exemplo, é o caso das *deep fakes*,

um tipo de produção que a IAG de imagens sofisticou ao mesmo tempo que automatizou sua execução (cf. Teccogs, 2021). Também pode acontecer que os bancos de dados estejam viciados, contaminando o que se seguirá. Ademais os desenvolvedores podem ser negligentes em seus cuidados com a ética. Como se não bastasse, os resultados que a IA passa à frente podem servir para atender interesses escusos das mais diversas espécies.

A IA é racista? Um dos problemas mais sérios da IA encontra-se nos vieses, considerando-se que muitos deles precedem as IAs e podem já estar presentes nos dados. Ora, dados não são neutros, portanto, não são confiáveis. Quando os dados não são bem selecionados, os vieses podem já estar presentes dentro da base de dados que é utilizada para o treinamento dos algoritmos. Por isso é sempre necessário levar em consideração a tendenciosidade de dados alimentados predominantemente por um público masculino, de pele clara e sem a devida representatividade e diversidade, seja socioeconômica, racial, étnica, regional ou de gênero.

A partir desses pressupostos cuidadosamente colocados em discussão, chegamos ao ponto de nos aproximar da educação, com um artigo sobre as mudanças significativas que a IA está trazendo para a educação, ressignificando as relações entre alunos e professores e levantando questões sobre a relevância futura das próprias instituições de ensino. A adoção da IA apresenta um conjunto complexo de avanços, incertezas e desafios. Apesar do potencial para aprimorar a aprendizagem e oferecer modelos inteligentes de personalização, preocupações éticas e o impacto no papel dos professores permanecem questões abertas. A integração da IA na educação, portanto, exige uma abordagem equilibrada, evitando extremos de otimismo ingênuo e pessimismo apocalíptico.

A pesquisa sobre o uso ético, incluindo a responsabilidade na geração de conteúdo acadêmico e a importância do pensamento crítico, é fundamental. Universidades e instituições carecem de diretrizes objetivas sobre o uso responsável dos modelos inteligentes, sendo necessário enfatizar a necessidade cada vez maior de transparência, de modo que as potencialidades da IA sejam capazes de incorporar os inerentes desafios éticos.

Por fim, um artigo propositivo completa o manual, com a proposta de um *framework* de design ético para a transformação do cenário educacional, abordando a colaboração entre uma instituição de ensino superior e inteligências artificiais, especialmente as generativas, desempenhando atividades antes exclusivas dos humanos. Diante da urgência de repensar as práticas de ensino-aprendizagem, especialmente nas avaliações tradicionais, surge o Design Ético de Modelo de Mudança, denominado *Aprend.ai*. Essa abordagem visa a fornecer à comunidade acadêmica um ambiente controlado para orientar a transição, revisando competências curriculares para integrar IAGs às práticas de ensino-aprendizagem, com a participação ativa de alunos e professores.

Apenas depois dessa série de artigos informativos e avaliativos é que um guia para a formação dos professores foi elaborado com a finalidade de orientar não só professores, alunos, administradores, mas também a própria instituição de ensino superior sobre o uso ético e responsável da IAG na educação. As regras estão distribuídas em quatro categorias principais, acompanhadas de seus subitens:

1. Ética da instituição de ensino superior

1.1 Quanto às medidas de prevenção e responsabilidade

1.2 Quanto à privacidade e proteção de dados

1.3 Quanto à fiscalização

Desenvolve-se aqui a necessidade de que as instituições de ensino elaborem suas políticas relativas à prevenção e contenção de riscos, uma maneira de garantia prévia para a preservação da segurança e proteção contra abusos e suas consequências.

2. Ética dos professores no uso da IAG com os alunos

- 2.1 Quanto à explicabilidade e transparência
- 2.2. Quanto ao consentimento informado e esclarecido
- 2.3. Quanto à inclusão e acessibilidade
- 2.4. Quanto à garantia de originalidade tanto à autonomia e ao pensamento crítico do aluno

A relação com os alunos, por envolver sempre questões delicadas e muitas vezes imprevisíveis, precisa ser cuidadosamente explicitada no sentido de sinais de alerta diante de usos que podem ferir princípios fundamentais da ética, em especial no que diz respeito ao uso enganoso que funciona contra o desenvolvimento da aprendizagem e da aquisição de conhecimento.

3. Ética dos alunos e pesquisadores em redação e pesquisas

- 3.1. Quanto à transparência na redação e pesquisa
- 3.2. Quanto à verificação de fontes
- 3.3. Quanto à garantia de originalidade
- 3.4. Quanto à prevenção ao plágio
- 3.5. Quanto ao processo contínuo de aprendizado
- 3.6. Quanto ao diálogo multidisciplinar

Embora o ChatGPT, em função de sua disseminação, continue funcionando como um mascote da IAG, a evolução desta tem sido alarmante. O número de plataformas para finalidades específicas cresce a olhos vistos, e o próprio GPT vai adquirindo crescentemente funções mais aprimoradas. Diante disso, fica muito difícil resistir às facilidades que apresenta para vários tipos de trabalhos. Só o diálogo entre professores e alunos é capaz de desenvolver mutuamente guias para a autoanálise sobre o uso devido.

4. Ética na formação de grupos e comitês

- 4.1. Quanto à inclusão e diversidade
- 4.2. Quanto à clareza e lisura nas operações
- 4.3. Quanto à educação e capacitação
- 4.4. Quanto ao diálogo contínuo
- 4.5. Quanto à análise crítica e reflexiva
- 4.6. Quanto à interlocução e às parcerias institucionais

Neste tópico são discutidas as relações de grupos interdepartamentais e, inclusive, interinstitucionais, cada instituição se instruindo a partir de experiências exemplares.

Para finalizar, uma síntese é apresentada, sinalizada por cores. Vermelho: evitar; Amarelo: alerta; Verde: encorajar. Esse trabalho não apenas é pioneiro nos seus propósitos, mas também nos dá muito orgulho no sentido de abertura de um caminho a ser trilhado e que, por isso, merece ser conhecido e, com sorte, reconhecido.

Notas de Finalização

A proliferação de grandes modelos de linguagem tem positivamente levantado preocupações crescentes sobre seu uso indevido, particularmente em casos em que textos gerados por IA são falsamente apresentados como se fossem de autoria humana. Certamente, estamos aí diante de um problema ético de enganação por razões que são situadas, quer dizer, que funcionam de modo específico em cada situação particular, devendo assim serem tratadas. Diante disso, no caso do ensino, não é surpreendente que venham surgindo detectores automáticos para a identificação de autoria.

Conhecemos de longa data o sucesso dos detectores de plágio que hoje funcionam em frações de

segundos graças à potência dos motores de busca. Embora muitos pensem que os textos produzidos por grandes modelos de linguagem tenham funcionamento similar e alardeiem os frágeis diagnósticos de que um texto produzido por IA – que finge sua autoria – possa ser chamado de plágio, esse diagnóstico é equivocado. A lógica de funcionamento da IAG é distinto. Por isso já estão popularizados alguns detectores (RADAR, Wild, T5Sentinel, Fast-DetectGPT, PHD, LogRank, Binoculars) em uma variedade de domínios. Entretanto, há já artigos que colocam esses detectores em discussão. Antes de tudo, vem sendo evidenciado que mesmo esforços moderados podem escapar significativamente da detecção. Por isso já se fala em verdadeiros positivos em oposição a falsos positivos (Tufts; Zhao; Li, 2025).

É certo que os professores precisam se manter atualizados em relação aos recursos que já existem de detecção de fraudes, em prol da credibilidade e responsabilidade acadêmica. Entretanto, é preciso estar alerta em relação aos falsos positivos e ao mal que se pode provocar em um estudante falsamente discriminado quanto ao uso enganoso da IAG. Reverter uma acusação é dificultoso e não saneia os danos psíquicos que provoca. Portanto, pode-se concluir sem muita dificuldade sobre a relevância do manual ético aqui exposto. Nada pode substituir a educação ética tanto institucionalmente pensada quanto pessoal, que se desenvolve na conversação a qual – longe de implicar proibição, que é um erro – orienta para o uso responsável e honesto não só em relação ao outro, mas sobretudo em relação a si mesmo.

Conflito de Interesse

Nada a declarar.

Disponibilidade de Dados de Pesquisa

Todos os dados foram analisados/gerados no presente artigo.

Financiamento

Não se aplica.

Agradecimentos

Não se aplica.

Referências

COUTO, E.; PORTO, C.; SANTOS, E. (org.). **App-learning**: experiências de pesquisa e formação. Salvador: Edufba, 2016.

DICKSON, B. How artificial intelligence is shaping the future of education. **PC MAG**. New York, 20 nov. 2017. Disponível em: <https://www.pcmag.com/news/how-artificial-intelligence-is-shaping-the-future-of-education>. Acesso em: 10 ago. 2021.

- HOLMES, W.; BIALIK, M.; FADEL, C. **Artificial intelligence in education: promises and implications for teaching & learning**. Boston: Center for Curriculum Redesign, 2019.
- LOOI, C-K. et al. (org.). **Artificial intelligence in education: supporting learning through intelligent and socially**. Amsterdam: IOS Press, 2005.
- LUCKIN, R. et al. **Intelligence unleashed: an argument for AI in education**. London: Pearson Education, 2016.
- ORGANIZAÇÃO DAS NAÇÕES UNIDAS PARA A EDUCAÇÃO, A CIÊNCIA E A CULTURA. **Consenso de Beijing sobre a inteligência artificial e a educação**. Paris: Unesco, 2019.
- ORGANIZAÇÃO DAS NAÇÕES UNIDAS PARA A EDUCAÇÃO, A CIÊNCIA E A CULTURA. **IA and education: guidance for policy makers**. Paris: Unesco, 2021.
- PROFUTURO; OEI. **El futuro de la inteligencia artificial en educación en América Latina**. [s. l.]: ProFuturo; OEI, 2023.
- RÖHE, A. A antropomorfização da inteligência artificial: como e por que os humanos julgam as máquinas. In: SANTAELLA, L. (org.). **O mal-estar na cultura revisitado**. São Paulo: Estação das Letras e Cores, 2024. p. 183-200.
- SANTAELLA, L. **Navegar no ciberespaço: o perfil cognitivo do leitor imersivo**. São Paulo: Paulus, 2004.
- SANTAELLA, L. **Humanos hiperhíbridos: linguagens e cultura na segunda idade da internet**. São Paulo: Paulus, 2021.
- SANTAELLA, L. **Há como deter a invasão do ChatGPT?** São Paulo: Estação das Letras e Cores, 2023.
- SANTAELLA, L. Novos dilemas da IA: a inteligência quer se expandir e o organismo quer perdurar: por que e como a IA generativa pensa e raciocina. **Cadernos IHU Ideias**, v. 22, n. 366, 2024. Disponível em: <https://www.ihu.unisinos.br/images/stories/cadernos/ideias/366cadernosihuideias.pdf>. Acesso em: 6 jun. 2025
- TECCOGS. n. 23 (2021): Deepfake. **Revista Digital de Tecnologias Cognitivas**. São Paulo, 12 out. 2021. Disponível em: <https://revistas.pucsp.br/index.php/teccogs/issue/view/n23>. Acesso: 6 jun. 2025.
- TUFTS, B; ZHAO, X.; LI, L. A practical examination of AI-generated text detectors for large language models. **Findings of the Association for Computational Linguistics**, p. 4.839-4856, 2025. Disponível em: https://arxiv.org/abs/2412.05139?utm_source. Acesso: 1 maio 2025.

Sobre a Autora

LUCIA SANTAELLA é pesquisadora 1 A do Conselho Nacional de Desenvolvimento Científico e Tecnológico (CNPq), professora titular na pós-graduação em Comunicação e Semiótica e em Tecnologias da Inteligência e Design Digital da Pontifícia Universidade Católica de São Paulo (PUC-SP). Doutora em Teoria Literária pela PUC-SP e livre-docente em Ciências da Comunicação pela Universidade de São Paulo (USP). Fez doze estágios de pós-doutorado no exterior e foi professora e pesquisadora convidada em várias universidades europeias e latino-americanas. Já levou à defesa 310 mestres, doutores e pós-doutores. Publicou 57 livros e organizou 34, além da publicação de quase 500 artigos no Brasil e no exterior. Recebeu os prêmios Jabuti (2002, 2009, 2011, 2014), Sergio Motta (2005), Luiz Beltrão (2010) e Thomas Sebeok (2025).

Recebido: 2 maio 2025

Aceito: 7 jul. 2025