

AGENDA BRASILEIRA

INTELIGÊNCIA ARTIFICIAL

Ano 6, nº 10, 2025



IMPACTO DA INTELIGÊNCIA ARTIFICIAL NA ORGANIZAÇÃO E NA RECUPERAÇÃO DA INFORMAÇÃO

João Alberto de Oliveira Lima¹

1 Analista de informática legislativa do Prodasen (Senado Federal), doutor em direito e em ciência da informação pela Universidade de Brasília (UnB).

1. INTRODUÇÃO

A inteligência artificial reemergiu na última década como uma tecnologia disruptiva, afetou várias áreas de conhecimento e já é sentida como fator transformador dos modos de organizar e recuperar informações em escala global. Desde os primórdios da biblioteconomia e ciência da informação, a organização do conhecimento baseou-se em processos manuais de classificação (como esquemas de classificação bibliográfica) e indexação por vocabulário controlado (tesauros e listas de cabeçalhos de assunto). A recuperação da informação, por sua vez, historicamente dependia de buscas sintáticas por palavras-chave, em que sistemas retornavam resultados apenas quando os termos consultados correspondiam exatamente aos termos indexados nos documentos. Esse paradigma tradicional, embora bem estabelecido, apresentava limitações conhecidas: a dificuldade de lidar com sinônimos, variações linguísticas e ambiguidades semânticas frequentemente comprometiam a eficácia das buscas.

A revolução promovida pela IA começou a ganhar forma com o desenvolvimento de algoritmos de aprendizado de máquina capazes de automatizar tarefas intelectuais. No domínio da recuperação da informação, evoluímos de simples correspondência de uma cadeia de caracteres (*strings*) para modelos estatísticos e, mais recentemente, para técnicas de aprendizado profundo (*deep learning*). Em particular, a introdução de representações vetoriais densas de linguagem – os chamados *embeddings* – e de arquiteturas baseadas em *transformers* trouxeram avanços notáveis na capacidade de os sistemas entenderem o conteúdo textual em nível semântico. Diferentemente das abordagens tradicionais, que tratavam termos isoladamente, essas novas técnicas permitem captar contexto e significado de palavras e documentos, aproximando a máquina da forma humana de compreender informações. Modelos de linguagem de grande porte, como BERT e GPT, ilustram essa mudança: por meio dos *embeddings* gerados em suas camadas internas, conseguem reconhecer que “carro” e “automóvel” são semanticamente relacionados, ou distinguir significados da palavra “banco” (assento ou instituição financeira) a partir do contexto em que aparece. Essas capacidades resolvem problemas clássicos da linguagem natural que oneravam os processos de indexação e recuperação – por exemplo, a sinonímia e a polissemia – e reduzem a necessidade de intervenção humana para normalização de termos.

Nesse contexto, observa-se uma transição clara de métodos tradicionais para abordagens baseadas em *embeddings* e em geração enriquecida por recuperação (*retrieval-augmented generation* – RAG). Ferramentas de busca de última geração deixam de se apoiar exclusivamente em correspondências exatas de palavras e passam a explorar similaridades em um espaço vetorial de alta dimensão, no qual textos com conteúdos semanticamente próximos ficam localizados a pequenas distâncias uns dos outros. Além disso, técnicas de RAG combinam a potência explicativa dos modelos de linguagem com bancos de conhecimento externos, o que possibilita respostas precisas apoiadas em documentos relevantes recuperados automaticamente. Essa transição tecnológica redefine a eficiência na gestão informacional: tarefas que antes consumiam grande esforço – como catalogação, classificação de documentos e construção de índices tornam-se mais ágeis e consistentes com auxílio de algoritmos inteligentes. Não por acaso, estudos recentes em ciência da informação no Brasil indicam certo crescimento do interesse na aplicação da IA justamente em organização e representação da informação, acompanhando a ascensão do *machine learning* na área (Pinheiro; Oliveira, 2022).

O objetivo deste ensaio é analisar como a inteligência artificial está redefinindo os paradigmas de organização e recuperação da informação, com destaque para os ganhos de eficiência e inovação, e também os desafios e mudanças profissionais implicados. Em especial, discute-se como a classificação do conhecimento tende a ganhar protagonismo na era da IA – servindo como alicerce estrutural para sistemas inteligentes – enquanto a indexação tradicional baseada em vocabulários controlados perde parte de sua relevância, à medida que os *embeddings* e modelos semânticos conseguem superar limitações da linguagem natural.

Este artigo está organizado conforme a seguir: a seção 1 traz a introdução, que contextualiza o tema e apresenta os objetivos do trabalho. A seção 2 explora os fundamentos teóricos dos *embeddings* e das arquiteturas *transformers* e evidencia como essas técnicas representam a informação em nível semântico. Na seção 3, discute-se a transição da busca sintática para a busca semântica e exemplifica-se o uso de sistemas RAG. Em seguida, a seção 4 aborda a automatização e a reestruturação dos processos de organização da informação promovidas pela IA, incluído seu impacto em vocabulários controlados, indexação e classificação, além de ana-

lizar a reconfiguração do papel dos profissionais da informação. A seção 5 aprofunda a discussão acerca da recuperação da informação potencializada pela IA e destaca novos paradigmas de interação e geração de respostas. Por fim, na seção 6, apresentam-se as considerações finais, com consolidação dos principais achados do estudo e indicação das perspectivas para pesquisas futuras.

2. FUNDAMENTOS TEÓRICOS – *EMBEDDINGS* E *TRANSFORMERS* NA REPRESENTAÇÃO DA INFORMAÇÃO

A compreensão de como a inteligência artificial representa informação textual é fundamental para se avaliar seu impacto na organização e recuperação de dados. Dois conceitos técnicos estão no cerne dessa revolução: os *embeddings* e os *transformers*.

Embeddings são representações numéricas densas de elementos linguísticos (palavras, frases ou documentos) em um espaço vetorial contínuo de alta dimensionalidade. Em termos simples, um *embedding* converte um termo ou texto em um vetor de números de forma que a proximidade geométrica entre dois vetores reflita a similaridade de significado entre os textos correspondentes. Assim, palavras com sentido próximo tendem a ter vetores próximos no espaço vetorial. Essa característica permite capturar relações semânticas e contextuais de modo que não era viável com representações lexicais discretas. Em contraste com a mera contagem de frequência de termos ou atribuição de identificadores únicos para cada palavra (como ocorria nos modelos de *bag of words* e indexação tradicional), os *embeddings* incorporam no valor dos vetores as sutilezas de uso e contexto. Por exemplo, um modelo de *embedding* bem treinado entenderia que o sentido de “morar” está mais próximo de “residir” do que de “casa”, apenas por cálculos de proximidades entre vetores.

O desenvolvimento de *embeddings* teve marcos importantes, como os modelos Word2Vec (Mikolov *et al.*, 2013) e GloVe (Pennington; Socher; Manning, 2014), que demonstraram ser possível aprender automaticamente, a partir de grandes coleções de textos, por meio de vetores que capturam relações de sinonímia, analogias e campos semânticos. Contudo, uma limitação dos *embeddings* iniciais, chamados “estáticos”, era atribuir-se a cada palavra um único vetor, independentemente

do contexto em que ela aparece. Isso dificultava lidar adequadamente com polissemias; por exemplo, a palavra “manga” teria o mesmo *embedding* quer fosse usada para se referir a uma fruta ou a uma parte da camisa. A solução para esse problema veio com o advento dos *embeddings* contextuais, produzidos por modelos baseados em *transformers*.

Os *transformers* constituem uma arquitetura de redes neurais introduzida por Vaswani *et al.* (2017) no artigo seminal “*Attention is all you need*”. Diferentemente dos modelos sequenciais anteriores (como redes recorrentes ou LSTM), os *transformers* utilizam mecanismos de autoatenção que permitem modelar as dependências entre todas as palavras de um texto em paralelo, independentemente da distância entre elas. Essencialmente, o mecanismo de autoatenção avalia a relevância de cada palavra em relação a todas as outras na sentença e gera representações mais ricas de cada termo, considerado seu contexto global. Essa inovação possibilitou a captura de relacionamentos de longo alcance em uma sequência textual de forma muito mais eficaz. Modelos de linguagem baseados em *transformers*, como o BERT (*bidirectional encoder representations from transformers*), demonstraram a capacidade de gerar *embeddings* altamente contextuais. Em outras palavras, o BERT fornece um vetor (*embedding*) diferente para uma mesma palavra a depender do contexto – o que significa que banco (instituição financeira) e banco (móvel para se sentar) deixam de ser uma confusão para o sistema, pois cada ocorrência terá representações vetoriais distintas conforme o sentido na frase.

A combinação de *embeddings* e *transformers* proporciona uma representação dinâmica e contextualizada dos dados. Em vez de uma organização estática baseada em campos ou descritores predefinidos, os documentos podem agora ser organizados automaticamente de acordo com similaridades temáticas identificadas pelos modelos de IA. Por exemplo, um *corpus* de artigos científicos pode ser vetorizado de modo que textos sobre temas similares formem agrupamentos no espaço vetorial, ainda que usem terminologias diferentes. Essa organização latente possibilita métodos mais eficientes de recuperação: uma consulta também convertida em vetor poderá “navegar” por esse espaço e recuperar itens próximos (semelhantes em conteúdo) mesmo que não compartilhem palavras-chave evidentes. Comparativamente, modelos sintáticos de busca – como os baseados em operadores booleanos ou em métricas de similaridade lexical (TF-IDF, BM25,

etc.) – atuam de forma literal e requerem correspondência explícita de termos. Tais modelos frequentemente falham em retornar resultados pertinentes se o usuário não adivinha exatamente o termo indexado ou se o documento expressa a ideia com vocabulário distinto. Já os modelos baseados em *embeddings* transcendem essa limitação ao compreender conceitos subjacentes. Em síntese, a teoria por trás de *embeddings* e *transformers* fornece o alicerce para sistemas de informação que entendem contexto e significado, o que torna possível uma organização da informação muito mais flexível e uma recuperação semântica mais poderosa do que jamais foi conseguido com técnicas convencionais.

3. DA BUSCA SINTÁTICA À SEMÂNTICA – AVANÇOS NA RECUPERAÇÃO DA INFORMAÇÃO

A recuperação da informação está passando por uma evolução significativa, migrando de abordagens sintáticas baseadas em correspondência literal de termos para métodos semânticos impulsionados pela IA.

Historicamente, os primeiros sistemas de recuperação – incluídos catálogos bibliográficos e mecanismos de busca na *web* nas décadas passadas – operavam majoritariamente de forma sintática. Isso significa que, ao submeter uma consulta, o usuário dependia de palavras-chave exatas: os algoritmos verificavam quais documentos continham os termos especificados (ou variações muito próximas) e baseavam a ordenação do resultado em fatores como contagem de ocorrências ou *links* (no caso do PageRank do Google). Tal modelo, embora eficiente computacionalmente, não reconhecia quando uma pergunta era feita em palavras diferentes daquelas presentes no documento relevante. Assim, uma busca por “doença cardíaca” poderia não recuperar um artigo cujo título fosse “cardiopatia”, caso não houvesse sinonímia mapeada manualmente no índice. Esse problema de vocabulário – a discrepância entre as palavras do usuário e as do autor do documento – resultava tanto em baixa revocação (perda de documentos relevantes por não coincidirem os termos) quanto em baixa precisão (retorno de documentos não relevantes pelo uso ambíguo de termos). A solução tradicional envolvia considerável trabalho de indexação: bibliotecários e analistas de informação atribuíam descritores normalizados aos documentos (de tesouros ou listas controladas) e os mecanismos de

busca permitiam expansão manual de consulta (por sinônimos, por exemplo). Ainda assim, essa abordagem manual tinha limites diante do volume crescente de informação e da diversidade de linguagem natural.

Os avanços em IA trouxeram a tão almejada busca semântica – sistemas capazes de ir além da superfície textual e recuperar informações pelo seu significado. Uma peça-chave nessa evolução foram os modelos de *dense retrieval*, que utilizam *embeddings* para representar consultas e documentos no mesmo espaço vetorial. Diferentemente do índice invertido tradicional (palavra > lista de documentos), esses sistemas avaliam similaridade por meio da distância vetorial entre a consulta e os documentos. Pesquisas têm demonstrado ganhos de eficácia notáveis com essa abordagem. Por exemplo, Zhuang e seu grupo de pesquisa (2023) relatam que os métodos de recuperação densa apresentam maior efetividade do que as técnicas baseadas em correspondência de palavras-chave como BM25, principalmente devido aos aspectos semânticos codificados nos modelos de linguagem pré-treinados subjacentes. Em outras palavras, um sistema de busca semântica apoiado em *embeddings* pode reconhecer a pertinência de um documento mesmo que este não contenha literalmente os termos da consulta, desde que haja proximidade de significado. Isso aumenta a probabilidade de se recuperar tudo o que for relevante (melhorando a revocação) sem sacrificar a precisão, pois a similaridade semântica atua como filtro contextual.

Um exemplo concreto dessa mudança de paradigma é a incorporação de perguntas e respostas semânticas nos buscadores atuais. Ao digitar uma pergunta em linguagem natural, usuários esperam que o sistema entenda a necessidade semântica do usuário e forneça uma resposta direta ou documentos específicos. Com modelos *transformers* tipo BERT integrados aos motores de busca, perguntas como “Qual é o impacto da IA na biblioteconomia?” podem ser compreendidas em seu sentido e associadas a documentos que discutem a aplicação de inteligência artificial em bibliotecas, mesmo que usem outras expressões.

Os sistemas de recuperação de informação aumentada por geração (*retrieval-augmented generation*) representam avanço ainda mais sofisticado nessa trajetória. O RAG combina um componente de recuperação tradicional (ou semântica) com um componente de geração de linguagem natural. Basicamente, diante de uma consulta, o sistema RAG primeiro recupera documentos ou trechos relevantes de uma

base de conhecimento e, em seguida, um modelo generativo (como GPT) sintetiza uma resposta utilizando essas informações. Isso oferece o melhor dos dois mundos: a precisão factual da busca baseada em fonte confiável e a fluidez explicativa de um modelo de linguagem. Gao e sua equipe (2024) descrevem que o RAG surgiu como solução promissora para contornar limitações de modelos puramente generativos – como alucinações e conhecimento desatualizado – pois incorpora conhecimento de bases externas, o que melhora a precisão e a credibilidade da geração. Em essência, o RAG alinha o conhecimento intrínseco de um modelo de IA (treinado em vastos dados, mas fixo até certo ponto) com conhecimentos atualizados e específicos de um repositório. Por exemplo, um usuário pode perguntar ao sistema RAG “Quais as vantagens do uso de *embeddings* na recuperação da informação?” e receber uma resposta articulada que, ao mesmo tempo em que explica o conceito em linguagem natural, referencia conteúdos técnico-científicos sobre o assunto. Isso difere radicalmente da experiência de busca tradicional, na qual o usuário precisaria por si só ler diversos documentos para sintetizar a resposta.

Outra vantagem da busca semântica é a tolerância a variações linguísticas e a consultas complexas. Esses sistemas conseguem lidar com erros de digitação, gírias, perguntas longas ou estruturadas de modo pouco convencional, pois os modelos de linguagem aprenderam sob um conjunto robusto de documentos ou representações. Enquanto antigamente uma consulta mal formulada podia falhar completamente, hoje os modelos conseguem “entender” mesmo pedidos imperfeitos. A robustez é tanta que já existem métodos para se lidar com grafias incorretas em consultas, integrando correção ortográfica no espaço vetorial dos *embeddings*, de modo que consultas com erros de digitação (*typos*) ainda encontrem resultados relevantes (Zhuang *et al.*, 2023).

Em síntese, argumenta-se que a transição da busca sintática para a semântica ampliou significativamente a precisão, a revocação e a relevância na recuperação da informação. Os usuários passam a ter menos necessidade de conhecer termos exatos ou lógica booleana; podem expressar suas necessidades informacionais em linguagem natural e confiar que o sistema dotado de IA interpretará corretamente o significado. Isso democratiza o acesso à informação, pois reduz a barreira técnica na interação com sistemas de busca. Além disso, possibilita novas aplicações, como assistentes virtuais capazes de responder perguntas em tempo real mediante

consulta a bases de dados (*chatbots* informacionais), sistemas de apoio à decisão que buscam precedentes em textos jurídicos, ou agregadores de notícias que entendem tópicos relacionados.

Um caso notável encontra-se no domínio jurídico: Oliveira Lima (2024) propôs um método de recuperação legal baseado em *embeddings* multi-nível, capaz de criar vetores não apenas para artigos de normas, mas também para parágrafos, incisos, títulos, capítulos, etc. e de capturar sutilezas do texto legal em diferentes granularidades. Isso permitiu a um sistema RAG jurídico fornecer respostas acuradas tanto sobre seções específicas quanto sobre o contexto mais amplo de uma lei, mesmo quando a consulta do usuário não correspondia exatamente às palavras do texto normativo. Tal abordagem reforça que a busca semântica não apenas encontra documentos, mas consegue apontar trechos ou pedaços de conhecimento pertinentes de forma adaptada à necessidade do usuário, algo impraticável com tecnologias sintáticas.

Portanto, a evolução para recuperação da informação semântica, exemplificada por *embeddings* e sistemas RAG, representa um avanço qualitativo. Os sistemas atuais entendem o conteúdo e a intenção de busca, em vez de meramente fazer comparações literais. Isso expande os horizontes do que significa “recuperar informação”, e aproxima-nos de mecanismos que agem como verdadeiros assistentes inteligentes de pesquisa, capazes de dialogar com o usuário e navegar por vastos repositórios de conhecimento de maneira ágil e relevante.

4. AUTOMATIZAÇÃO E REESTRUTURAÇÃO NA ORGANIZAÇÃO DA INFORMAÇÃO

Com os avanços da inteligência artificial, os métodos tradicionais de organização do conhecimento estão sendo profundamente automatizados e reestruturados. Nessa nova conjuntura, a classificação ressurgiu com destaque como o principal eixo da organização informacional na era da IA. Já na época da *web* semântica observou-se um “novo e imenso interesse pela classificação, pela taxonomia e pelo desenvolvimento de ontologias” (Gomes; Guimarães, 2010), que marcou a valorização desses sistemas no domínio da organização do conhecimento. A literatura destaca, também, o método de classificação facetada como abordagem consensual

para se dar conta da complexidade semântica na internet. Agora, com técnicas modernas de IA, esse protagonismo da classificação se intensifica, pois torna-se possível a aplicação desses princípios em escala e de forma automatizada e garante-se uma estrutura conceptual sólida para organização de entidades informacionais.

Em contraste com a classificação, a indexação tradicional – entendida como a atribuição de descritores ou termos de assunto a documentos – tende a perder terreno enquanto atividade manual autônoma. Modelos de *embedding* (incorporação vetorial) eliminam a necessidade de indexação manual, ao representar automaticamente o conteúdo de documentos em vetores de alta dimensionalidade que capturam seu sentido semântico. Na era do *deep learning*, as características relevantes de um item de informação deixam de ser definidas por humanos e passam a ser determinadas implicitamente pelo modelo treinado, sem necessidade de escolher termos explícitos. Significa que problemas clássicos da indexação, como a sinonímia e a polissemia, são resolvidos de forma elegante: a representação vetorial aproxima conteúdos conceitualmente semelhantes e separa contextos distintos automaticamente.

Por exemplo, uma busca semântica baseada em *embeddings* é capaz de transcender correspondências literais de palavras-chave e retornar documentos sobre maçãs e laranjas mesmo que a consulta original do usuário tenha sido “fruta”. Esse mecanismo demonstra que os modelos de linguagem conseguem interpretar a intenção por trás dos termos ao alinhar sinônimos e relacionar conceitos correlatos sem requerer descritores humanos pré-definidos. Em outras palavras, o algoritmo extrai por conta própria os aspectos temáticos de cada documento, codifica-os matematicamente e substitui por completo a etapa de indexação intelectual. Assim, o custo antes associado à indexação – seja em horas de trabalho de indexadores ou em manutenção de vocabulários controlados – será virtualmente eliminado pelo uso de *embeddings*. Todo o processo de análise de conteúdo e geração de pontos de acesso se tornará um subproduto automático do processamento de linguagem natural, o que remove a necessidade de se atribuírem descritores manualmente. Consequentemente, a indexação deixará de figurar como componente separado e oneroso do ciclo informacional e se integrará de forma transparente à etapa de análise feita pelos modelos de IA.

Diante desse cenário, a classificação consolida-se como eixo central da organização da informação. Sem a carga operacional da indexação manual, os esforços podem se concentrar na definição de boas estruturas classificatórias que orientem a organização do acervo de conhecimento. A classificação provê uma visão macro, agregando os objetos informacionais em categorias lógicas, e essa organização hierárquica ou facetada serve de espinha dorsal para os sistemas informacionais inteligentes. Mesmo nos primórdios da automação, reconhecia-se que instrumentos clássicos de classificação (como taxonomias) possuíam potencial para melhorar a navegação e a recuperação de informações. Agora, a IA amplia esse potencial ao aplicar esquemas classificatórios de forma consistente e em larga escala e garante que a base de conhecimento esteja bem estruturada conceitualmente antes mesmo de qualquer consulta do usuário.

A classificação, ao impor uma estrutura estável e rigorosa para a organização de entidades, complementa e aprimora os resultados obtidos pelos modelos de linguagem. Enquanto o *embedding* lida com nuances semânticas em níveis macro e micro (de termos e contexto local), a classificação lida com a organização macro do saber, agrupando conteúdos em domínios e categorias amplas. Essa dupla abordagem cria um sistema híbrido poderoso: por um lado, elimina-se a indexação exaustiva de cada documento, pois o modelo já entende seu conteúdo em vários níveis de granularidade; por outro, mantém-se uma visão categórica global que ajuda a contextualizar a informação. Estudos recentes em organização do conhecimento mostram que os processos de classificação e categorização compõem juntos a base teórica do campo, porque são complementares: a classificação fornece estrutura estável enquanto a categorização traz flexibilidade (Lima; Maculan, 2024). Na prática, os sistemas de IA conseguem agora tirar proveito dessas duas características simultaneamente, algo antes difícil de se alcançar. A classificação automatizada orientada por IA pode, por exemplo, auxiliar na navegação por grandes coleções e na restrição ou expansão de buscas conforme facetas ou categorias relevantes, funcionalidades antes alcançadas apenas parcialmente pelos sistemas de organização tradicionais (Gomes; Guimarães, 2025). Desse modo, a classificação torna-se a peça-chave que alinha a organização intrínseca do conhecimento com os mecanismos automatizados de tratamento da informação.

Além de reforçar a importância da classificação tradicional, a IA abre caminho para novos sistemas de classificação capazes de atender a necessidades avançadas e específicas. Diferentemente dos esquemas estáticos convencionais, agora é possível imaginarmos critérios inéditos e flexíveis de categorização, definidos a partir dos dados e ajustados iterativamente pelos algoritmos. Em vez de um único arranjo hierárquico predeterminado, podemos ter múltiplas visões classificatórias coabitando o mesmo sistema, escolhidas conforme a demanda informacional. A seguir, listamos duas possibilidades viabilizadas ou ampliadas pela IA:

- Geração semiautomática de ontologias e taxonomias: técnicas de aprendizado de máquina (particularmente as não supervisionadas, como algoritmos de *clustering*) conseguem detectar padrões e relações latentes nos dados, o que possibilita a descoberta de novas categorias ou conceitos. A partir de grandes coleções de documentos, a IA pode sugerir ontologias, identificando termos-chave e organizando-os em hierarquias ou redes de conceitos. Essas ontologias geradas de forma semiautomática podem complementar ou estender os esquemas existentes, atendendo a domínios especializados ou incorporando terminologias recém-criadas em campos de ponta. Nota-se, assim, uma flexibilidade inédita: os sistemas passam a evoluir suas categorias conforme o crescimento ou mudança do conhecimento, algo impraticável nos modelos de classificação fixos do passado.
- Classificação multidimensional e facetada avançada: a IA também facilita a implementação de classificações facetadas de forma abrangente. Num sistema tradicional, a classificação por facetas (por exemplo: tema, autoria, localização, período) dependia de metadados atribuídos manualmente. Com a IA, é possível extrair-se automaticamente múltiplas facetas de cada item – desde tópicos tratados, estilo textual, até sentimentos expressos – e classificar-se cada item simultaneamente em todas essas dimensões. Os usuários poderiam então filtrar e combinar categorias livremente (por exemplo: pesquisar por “relatórios técnicos” [gênero documental] sobre “energia solar” [assunto] publicados nos “últimos cinco anos” [tempo]) sem necessidade de que um indexador tenha previsto todas essas combinações. A classificação facetada torna-se

mais poderosa e acessível, pois as facetas relevantes são identificadas e atribuídas pela IA durante o processamento dos documentos.

Em suma, a automatização proporcionada pela IA não apenas mantém a espinha dorsal classificatória dos sistemas de informação como a torna mais maleável e adaptável. Critérios de organização que antes eram engessados em esquemas únicos agora podem coexistir e se transformar conforme as demandas. A IA permite a definição de novos princípios classificatórios ao combinar a solidez de uma organização bem estruturada com a plasticidade de categorizações ajustáveis. Tudo isso reforça o argumento de que a classificação – longe de ser suplantada – emerge como elemento central e estratégico na gestão da informação contemporânea, enquanto a indexação manual e onerosa fica obsoleta. A organização do conhecimento, assim vislumbrada, prepara o terreno para aprimoramentos igualmente significativos na outra face do problema: a recuperação da informação, conforme discutiremos a seguir.

5. RECUPERAÇÃO DA INFORMAÇÃO POTENCIALIZADA POR IA

Os avanços em organização informacional trazidos pela IA têm como contrapartida direta uma transformação na recuperação da informação. Com bases de dados estruturadas por classificações robustas e *embeddings* semânticos, os sistemas de busca atuais alcançam um patamar superior de eficiência e eficácia, uma vez que conseguem compreender a intenção por trás das consultas, o que demonstra habilidade em captar sinônimos e contextos. Essa superação da simples correspondência de palavras-chave significa um salto qualitativo: diminui-se a dependência da formulação exata da consulta pelo usuário, aumentando-se a probabilidade de recuperar informações pertinentes escondidas atrás de terminologias distintas.

Do ponto de vista técnico, a IA introduz algoritmos e estruturas de dados inovadores para implementar essa recuperação semântica em larga escala. Essencialmente, cada documento (ou objeto informacional) é mapeado a um vetor denso por meio de seu *embedding*, e consultas são igualmente convertidas em vetores; a busca

consiste em se encontrarem os vetores de documentos mais próximos do vetor da consulta. Usando essa abordagem multicamada, o mesmo processo pode considerar partes do documento como potenciais alvos de busca, sem necessidade de indexação e/ou uso de vocabulários controlados. Métodos como *nearest neighbors* permitem a realização dessa busca de similaridade de forma rápida, mesmo em coleções com milhões de vetores. O resultado é que a recuperação se torna simultaneamente mais inteligente e mais escalável: a inteligência vem da compreensão contextual proporcionada pelos modelos de linguagem, e a escalabilidade deriva de estruturas especializadas que lidam com altas dimensionalidades de dados.

Além de aprimorar a busca por documentos relevantes, a IA possibilita novos paradigmas de interação que vão além da simples recuperação, como a geração de respostas e a interação em linguagem natural com bases de conhecimento, e atende de forma mais direta à necessidade de informação do usuário. Grandes modelos de linguagem (LLM), treinados em volumes massivos de textos, conseguem responder perguntas dos usuários diretamente, sintetizando informações de múltiplas fontes. Com o surgimento da RAG, um modelo generativo primeiro efetua uma busca semântica em um repositório de dados e, em seguida, utiliza os resultados recuperados para compor uma resposta em linguagem natural. Por exemplo, dada uma pergunta complexa, o sistema pode extrair trechos relevantes de documentos (com o uso de *embeddings* para encontrar os trechos mais relacionados à pergunta) e então elaborar uma resposta coerente e contextualizada, com citação das fontes consultadas. Com isso, a recuperação da informação deixa de se resumir a uma lista de documentos e passa a incorporar elementos de resolução de problemas e atendimento informacional personalizado.

Mesmo nessa nova realidade os sistemas de classificação mantêm um papel fundamental nos bastidores da recuperação. Uma base de conhecimento organizada logicamente – seja por categorias, facetas ou ontologias – fornece um contexto estruturante que pode ser explorado pelos modelos de IA para refinar suas buscas e respostas. Ontologias bem delineadas atuam como “estrutura geral na qual catálogos, taxonomias e terminologias recebem organização adequada” e servem de alicerce para recuperação ótima de recursos informacionais (Gomes; Guimarães, 2025). Assim, há uma convergência entre as técnicas avançadas de recuperação semântica e os princípios clássicos de organização: a classificação e demais sistemas

de organização do conhecimento fornecem mapas e delineamentos, enquanto os modelos de IA são guias ágeis que percorrem esse terreno para encontrar exatamente o que se procura.

Como resultado, a experiência de recuperação da informação torna-se mais natural, precisa e rica em possibilidades. Natural, porque usuários podem fazer perguntas ou buscar por ideias em sua própria linguagem, na confiança de que o sistema entenderá seu pedido. Precisa, porque a combinação de *embeddings* e estrutura conceitual tende a aumentar a relevância dos resultados obtidos. Rica, porque agora é viável obterem-se informações elaboradas, agregadas de diversas fontes, em vez de apenas documentos isolados. Nesse contexto, o papel do profissional da informação também se transforma, pois, em vez de despendar esforços na indexação manual de cada item, pode focar em curar e melhorar os esquemas classificatórios e as bases de conhecimento que alimentam a IA, garantindo, assim, que tanto a organização quanto a recuperação se deem sobre fundamentos sólidos e confiáveis.

6. CONCLUSÃO

A incorporação da inteligência artificial na organização e recuperação da informação está redefinindo os alicerces da biblioteconomia e da ciência da informação. Conforme argumentado, a classificação emerge como eixo central desse novo ecossistema informacional, provendo a estrutura necessária para dar sentido ao volume crescente de dados. Longe de ser suplantada, a classificação – apoiada por ontologias, taxonomias e métodos facetados – ganha proeminência inédita ao orientar a organização do conhecimento em níveis macroscópicos que complementam a inteligência computacional. Paralelamente, a tradicional tarefa da indexação manual foi completamente automatizada e integrada aos modelos de IA. O uso de *embeddings* não apenas elimina os custos e esforços antes associados à indexação, como também supera suas limitações, oferecendo representações semânticas ricas que alimentam mecanismos de busca muito mais eficientes.

Com a indexação deixada para as máquinas, abre-se espaço para a criatividade humana na concepção de novos sistemas de categorização. A flexibilidade proporcionada pela IA viabiliza múltiplos esquemas classificatórios simultâneos, adaptações dinâmicas e evolução constante das categorias conforme surgem

novos conhecimentos. Essa plasticidade era inimaginável em meados do século XX, quando esquemas rígidos dominavam – agora, porém, torna-se parte integrante de uma ciência da informação orientada por dados e aprendizado de máquina.

No *front* da recuperação da informação, testemunhamos ganhos substanciais de desempenho e qualidade. As buscas tornaram-se mais semânticas, contextuais e responsivas às necessidades dos usuários. Em vez de listagens exaustivas e muitas vezes imprecisas, os usuários obtêm resultados afinados ao seu propósito, quicá respostas diretas elaboradas por sistemas inteligentes baseados no conhecimento acumulado. A sinergia entre organização bem estruturada e algoritmos avançados de recuperação resultou em sistemas capazes de entender perguntas complexas, localizar informações relevantes e entregá-las de forma sintética e útil.

Em termos de rigor acadêmico e de aplicação prática, fica evidente que a IA não torna obsoletos os princípios da organização do conhecimento – ao contrário, reafirma sua importância. A necessidade de coerência, consistência e contexto na estruturação da informação é ainda mais crucial quando delegamos a agentes artificiais a tarefa de buscar e filtrar conhecimento. Desse modo, profissionais da informação e pesquisadores são chamados a atuar em conjunto com sistemas de IA para treiná-los e alimentá-los com boas estruturas conceituais. O futuro da organização e da recuperação da informação, impulsionado pela IA, delineia-se como um campo altamente automatizado, porém intelectualmente orientado, no qual os arcabouços clássicos e as inovações tecnológicas se apoiam mutuamente.

Em conclusão, o impacto da inteligência artificial nesse domínio manifesta-se como uma revolução positiva: tarefas mecânicas e dispendiosas são automatizadas, enquanto atividades intelectuais de alto nível – como a classificação e a definição de novas formas de organização do conhecimento – ganham centralidade. Essa redistribuição de papéis promete não apenas otimizar a eficiência dos sistemas de informação, mas também ampliar as fronteiras do possível, o que nos permite organizar e recuperar o conhecimento humano de maneiras antes inatingíveis. Conforme a IA continua a evoluir, manter-se o diálogo entre algoritmos e princípios de organização será essencial para se assegurar que esse vasto potencial se traduza em acessibilidade informacional, descoberta de conhecimento e enriquecimento científico para a sociedade como um todo.

Referências

- GAO, Y. *et al.* **Retrieval-augmented generation for large language models: a survey.** 2023. Disponível em: <https://arxiv.org/abs/2312.10997>. Acesso em: 14 abr. 2025.
- GOMES, H. E.; GUIMARÃES, L. S. **Organização do conhecimento e recuperação da informação na era das tecnologias digitais.** Rio de Janeiro: UFRJ, 2010. Disponível em: <http://repositorio.febab.org.br/items/show/5350>. Acesso em: 14 abr. 2025.
- LIMA, G. A.; MACULAN, B. C. M. S. Universo do conhecimento: classificação e categorização sob o prisma da organização do conhecimento. **RDBCI: Revista Digital de Biblioteconomia e Ciência da Informação**, v. 22, n. 00, p. e024017, 2024. Disponível em: <https://periodicos.sbu.unicamp.br/ojs/index.php/rdbci/article/view/8675419> . Acesso em: 8 jul. 2025.
- LIMA, J. A. O. Unlocking legal knowledge with multi-layered embedding-based retrieval. **Artificial Intelligence in Legislative Services: Principles for Effective Implementation.** 2024. Disponível em: <https://arxiv.org/abs/2411.07739>. Acesso em: 14 abr. 2025.
- MIKOLOV, T. *et al.* Efficient estimation of word representations in vector space. **International Conference on Learning Representations 2013.** 2013. Disponível em: <https://arxiv.org/abs/1301.3781>. Acesso em: 14 abr. 2025.
- PENNINGTON, J.; SOCHER, R.; MANNING, C. GloVe: global vectors for word representation. In: Conference on Empirical Methods in Natural Language Processing, 19., 2014, Doha. **Proceedings [...]**. Doha: Association for Computational Linguistics, p. 1532-1543, 2014.
- PINHEIRO, M.; OLIVEIRA, H. Inteligência artificial: estudos e usos na ciência da informação no Brasil. **Revista Ibero-Americana de Ciência da Informação**, v. 15, n. 3, p. 950-968, 2022. Disponível em: <https://periodicos.unb.br/index.php/RICI/article/view/42767> . Acesso em: 8 jul. 2025.

VASWANI, A. *et al.* **Attention is all you need.** 2017. Disponível em: <https://arxiv.org/abs/1706.03762>. Acesso em: 14 abr. 2025.

ZHUANG, S. *et al.* **Typos-aware bottlenecked pre-training for robust dense retrieval.** 2023. Disponível em: <https://arxiv.org/abs/2304.08138>. Acesso em: 14 abr. 2025.